Benchmark des modèles Ollama — Plateforme de commande intelligente Givaudan

Équipe 14 · 10 novembre 2026

1. Contexte

Un client, souvent novice, décrit en français l'arôme qu'il cherche, par exemple « un arôme fruité pour un yaourt à boire ». Notre plateforme retrouve les arômes adaptés dans le catalogue, puis un modèle de langage lui répond comme un conseiller. Tout doit fonctionner en local, sans service externe.

Il nous faut donc choisir deux modèles : un pour **chercher** les bons arômes, et un pour **répondre** au client.

2. Méthodologie

- Nous avons posé les mêmes 8 demandes clients à chaque modèle, sur un catalogue fictif de 48 arômes.
- Tout a tourné sur notre ordinateur portable (7,9 Go de mémoire, sans carte graphique dédiée).
- **Recherche** : le bon arôme se trouve-t-il dans les 3 premiers résultats ?
- **Réponse** : les 4 modèles reçoivent les mêmes arômes. Nous mesurons le temps de réponse et le respect de 4 consignes : citer un arôme du catalogue, ne pas en inventer, répondre en français, finir par une question.

3. Résultats

Chercher les bons arômes

Modèle	Trouve au moins un bon arôme	Bonnes propositions
nomic-embed-text	100 %	42 %
bge-m3	100 %	50 %

bge-m3 trouve au moins un bon arôme pour 100 % des demandes, et 50 % de ses propositions sont justes (le maximum possible sur ce test est de 75 %). nomic-embed-text fait moins bien, avec 42 % de bonnes propositions.

Répondre au client

Modèle	Temps de réponse	Mémoire utilisée	Consignes respectées
qwen2.5:1.5b	23 s	1,1 Go	75 %
llama3.2:3b	59 s	2,4 Go	100 %
gemma3:4b	64 s	2,7 Go	100 %
qwen3.5:4b	73 s	2,9 Go	100 %

qwen2.5:1.5b est le plus rapide, avec 23 s en moyenne, mais il n'arrive pas à : finir par une question.

4. Notre choix

Nous choisissons **llama3.2:3b** pour répondre et **bge-m3** pour chercher.

- **Adapté à un client novice** : il répond en français, s'appuie sur les arômes du catalogue et finit par une question pour préciser le besoin.
- **Le plus rapide des modèles qui respectent toutes les consignes** : environ 59 s par réponse.
- **Compatible avec notre contrainte locale** : il utilise 2,4 Go de mémoire sur un ordinateur sans carte graphique dédiée.

Notre score compte 60 % pour la qualité et 40 % pour la vitesse. llama3.2:3b obtient 71/100. qwen2.5:1.5b a un score plus élevé grâce à sa vitesse, mais nous l'écartons car il ne respecte pas les consignes.

Ce résultat vient de 8 questions, d'un catalogue fictif et d'une seule machine : il reste à confirmer sur de vrais usages.