Benchmark des modèles Ollama — Plateforme de commande intelligente Givaudan

Équipe XXX

10 novembre 2026

1. Contexte et besoin

Un client de Givaudan, souvent novice, décrit son besoin en français, par exemple « un arôme fruité pour un yaourt à boire ». La plateforme doit retrouver les arômes adaptés dans un catalogue, puis répondre comme un conseiller.

Le système repose sur deux types de modèles :

- **Un modèle d'embeddings** transforme les textes en vecteurs pour retrouver les arômes proches de la demande (RAG).
- **Un LLM** rédige la réponse : dialogue en français, ton accueillant, 2 ou 3 arômes justifiés, puis une question pour préciser le besoin.

La contrainte principale est de fonctionner à 100 % en local, sans aucune API externe, sur un ordinateur portable modeste.

2. Méthodologie

Machine de test

Élément	Valeur détectée
Système	Windows 10 (10.0.19045)
Processeur	Intel(R) Core(TM) i5-6300U CPU @ 2.40GHz (4 cœurs logiques)
Mémoire vive	7,9 Go
Carte graphique	Intel(R) HD Graphics 520 (pas de GPU dédié, calcul sur CPU)

Modèles testés

Modèle	Rôle	Taille sur disque
nomic-embed-text	Embeddings	0,3 Go
bge-m3	Embeddings	1,1 Go
qwen2.5:1.5b	LLM	0,9 Go
qwen3.5:4b	LLM	3,1 Go
llama3.2:3b	LLM	1,9 Go
gemma3:4b	LLM	3,1 Go

Protocole

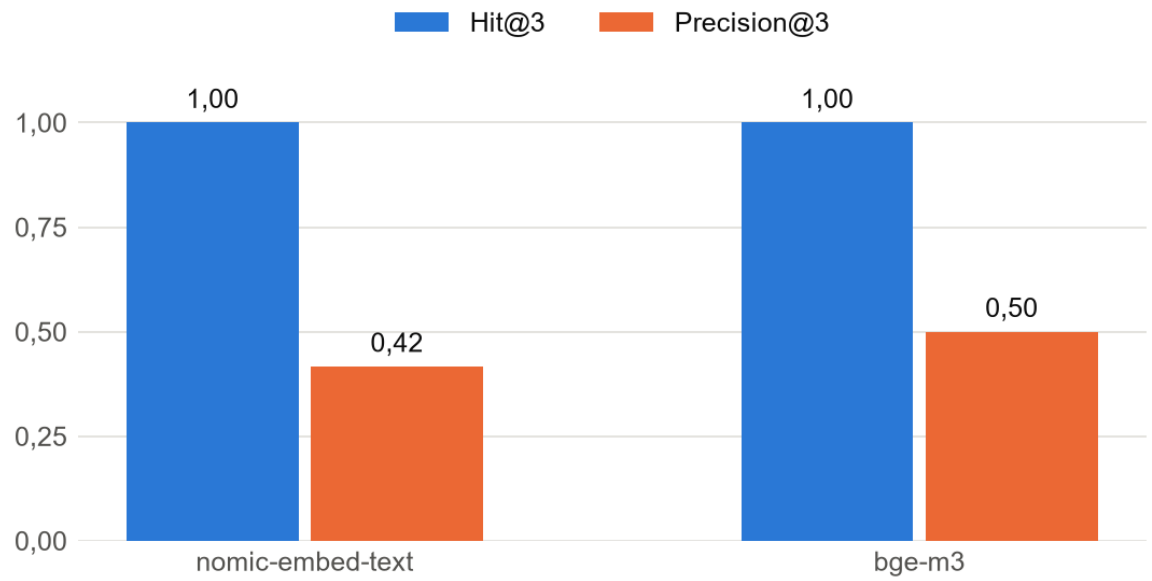
- 8 demandes clients en français, chacune avec ses arômes attendus (vérité terrain), sur un catalogue fictif de 48 arômes.
- Embeddings : top 3 par similarité cosinus. Hit@3 : au moins un arôme attendu dans le top 3. Precision@3 : part des 3 résultats qui sont attendus.
- LLM : même contexte pour tous (les 3 arômes trouvés par bge-m3, le meilleur en Hit@3 puis Precision@3), même consigne système.
- Température 0,2, mode thinking désactivé, réponse limitée à 400 tokens par sécurité.
- Un seul modèle en mémoire à la fois : un appel de chauffe non compté avant chaque modèle, puis déchargement après.
- Mesures issues d'Ollama : durée totale, chargement, tokens générés, vitesse et mémoire occupée.

- Qualité automatique : cite un arôme fourni, invente un arôme absent du catalogue (détection simple), répond en français, finit par une question.

3. Résultats des embeddings

Modèle	Hit@3	Precision@3	Indexation (48 arômes)	Temps par requête	RAM
nomic-embed-text	1,00	0,42	15,1 s	814 ms	0,4 Go
bge-m3	1,00	0,50	29,6 s	608 ms	1,2 Go

Hit@3 et Precision@3 par modèle d'embeddings (plus c'est haut, mieux c'est)



La Precision@3 ne peut pas dépasser 0,75 sur ce jeu de test, car certaines questions ont moins de 3 arômes attendus.

Le modèle retenu pour fournir le contexte aux LLM est **bge-m3**.

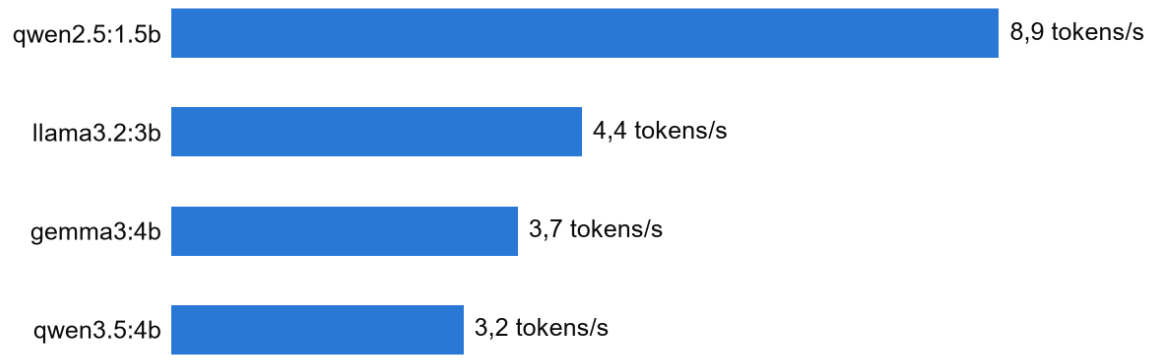
4. Résultats des LLM

Modèle	Temps moyen	Tokens /s	RAM	Cite un arôme	Invente	Français	Finit par une question	Note équipe
qwen2.5:1.5b	23,0 s	8,9	1,1 Go	100 %	0 %	100 %	0 %	—
qwen3.5:4b	73,1 s	3,2	2,9 Go	100 %	0 %	100 %	100 %	—
llama3.2:3b	58,6 s	4,4	2,4 Go	100 %	0 %	100 %	100 %	—
gemma3:4b	64,0 s	3,7	2,7 Go	100 %	0 %	100 %	100 %	—

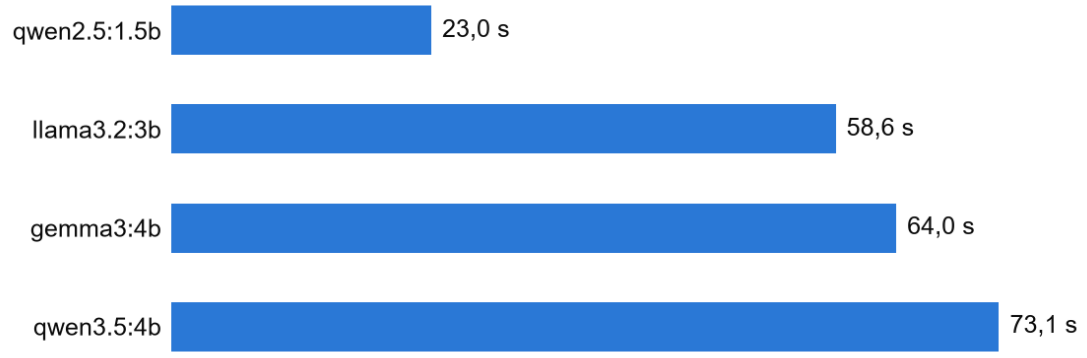
Temps de chargement à froid : qwen2.5:1.5b 7,6 s, qwen3.5:4b 25,2 s, llama3.2:3b 11,9 s, gemma3:4b 26,0 s.

Note équipe : pas encore renseignée dans manual_scores.csv.

Vitesse de génération en tokens par seconde (plus c'est long, mieux c'est)



Temps de réponse moyen en secondes (plus c'est court, mieux c'est)



5. Exemple de réponses

Question : « Je cherche un arôme fruité et sucré pour un yaourt à boire »

qwen2.5:1.5b

Je vous recommande le Fraise des bois (famille : Fruité rouge) pour votre yaourt à boire. Sa composition de fraises mûres et sucrée avec une acidulée légère et juteuse donne un goût fruité et sucré parfait. Ce yaourt sera apprécié par les enfants et les adultes.

qwen3.5:4b

Bonjour ! Pour votre yaourt à boire, voici trois options parmi nos arômes disponibles :
1. **Fraise des bois** : Un choix idéal car il offre une saveur de fraise mûre, légèrement acidulée et juteuse, parfaite pour le goût fruité que vous recherchez.
2. **Fruits rouges mélangés** : Cette poudre apporte un mélange rond et sucré (fraises, framboises, etc.), ce qui peut enrichir votre produit avec une touche variée.
3. **Poire Williams** : Si vous souhaitez une alternative différente, cet arôme liquide donne une sensation fondante et très sucrée, souvent utilisée dans les desserts.
Quelle direction préférez-vous pour commencer ?

llama3.2:3b

Pour votre yaourt à boire, je vous recommande les arômes suivants :
– Fraise des bois : cette fraise parfumée et sucrée ajoutera une touche de fraîcheur et de douceur à votre yaourt.
– Fruits rouges mélangés : cet assemblage de fraises, framboises, cassis et myrtilles apportera une dimension fruitée et sucrée à votre yaourt.
– Poire Williams : cette poire juteuse et fondante ajoutera une note de douceur et de profondeur à votre yaourt.
Quel est le volume d'arôme que vous souhaitez utiliser pour votre yaourt ?

gemma3:4b

Bonjour ! Pour un yaourt à boire fruité et sucré, je vous suggère plusieurs options.
Premièrement, la **Fraise des bois** apportera une base fruitée intense et parfumée, idéale pour un goût sucré et légèrement acidulé. Deuxièmement, l'**Fruits rouges mélangés** offre un profil fruité plus complexe, avec des notes de fraise, framboise, cassis et myrtille, pour un goût rond et fruité. Enfin, la **Poire Williams** apportera une douceur juteuse et fondante, parfaite pour adoucir le mélange.
Pourriez-vous me préciser quel type de douceur vous recherchez dans ce yaourt à boire ?

6. Recommandation

Chaque couple LLM + embeddings reçoit un score sur 100 : 60 % de qualité et 40 % de vitesse.

- **Qualité** : moyenne de la qualité du LLM (ses 4 indicateurs automatiques, et les notes de l'équipe pour moitié si elles existent) et de la qualité des embeddings (Hit@3 et Precision@3 ramenée à son maximum possible).
- **Vitesse** : temps total de réponse du couple, ramené au couple le plus rapide (100 = le plus rapide).

LLM	Embeddings	Qualité	Vitesse	Score
qwen2.5:1.5b	bge-m3	79	100	88
qwen2.5:1.5b	nomic-embed-text	76	99	85
llama3.2:3b	bge-m3	92	40	71
gemma3:4b	bge-m3	92	36	70
llama3.2:3b	nomic-embed-text	89	40	69
gemma3:4b	nomic-embed-text	89	36	68
qwen3.5:4b	bge-m3	92	32	68
qwen3.5:4b	nomic-embed-text	89	32	66

Couple recommandé : qwen2.5:1.5b + bge-m3, score 88/100.

Sur cette machine, qwen2.5:1.5b répond en 23,0 s en moyenne à 8,9 tokens/s, et sa qualité atteint 75/100 (moyenne des indicateurs automatiques). Il cite un arôme fourni dans 100 % des réponses, répond en français dans 100 % des cas, finit par une question dans 0 % des cas et invente un arôme dans 0 % des cas.

Côté recherche, bge-m3 obtient un Hit@3 de 1,00 et une Precision@3 de 0,50, pour environ 608 ms par requête.

La meilleure qualité (100/100) revient à : llama3.2:3b (58,6 s), gemma3:4b (64,0 s), qwen3.5:4b (73,1 s). Leur temps de réponse pèse sur leur score.

Point de vigilance : qwen2.5:1.5b gagne surtout grâce à sa vitesse, mais il respecte mal cette consigne : finir par une question (0 % des réponses). Si cette consigne est indispensable, le meilleur couple qui la respecte est **llama3.2:3b + bge-m3** (score 71/100).

Les notes manuelles de l'équipe ne sont pas encore renseignées : ce classement repose uniquement sur des indicateurs automatiques, qui ne jugent pas la pertinence du conseil.

7. Limites

- Le catalogue est fictif : 48 arômes créés pour la démo, sans données réelles Givaudan.
- Le jeu de test est petit (8 questions) : un écart de quelques points n'est pas significatif.
- Les mesures viennent d'une seule machine, qui exécutait d'autres applications : les temps changeraient sur un autre ordinateur.
- Les indicateurs automatiques sont simples : ils peuvent manquer un arôme inventé ou en signaler un à tort, et ne jugent pas la pertinence du conseil.
- Chaque LLM a été évalué avec le contexte d'un seul modèle d'embeddings.
- Pour le bouillon végétarien, 4 modèle(s) sur 4 citent « Poulet rôti » : ce contresens n'est pas détecté par les indicateurs automatiques, d'où l'intérêt des notes de l'équipe.